

# Laboratorium z rachunku prawdopodobieństwa

Zadania treningowe przed kolokwium zaliczeniowym  
(wersja Python)

## Spacer losowy i prawo iterowanego logarytmu

Rozważmy następujący prosty spacer losowy po osi liczbowej: umieszczamy pionek w punkcie 0, a następnie w każdym ruchu przesuwamy go losowo o 1 w prawo lub o 1 w lewo. Łącznie wykonujemy w ten sposób  $n$  ruchów. Formalnie definiujemy taki spacer w następujący sposób. Niech  $X_1, X_2, \dots, X_n$  będą niezależnymi zmiennymi losowymi, takimi, że

$$\mathbb{P}(X_i = -1) = \mathbb{P}(X_i = 1) = \frac{1}{2}, \quad i = 1, 2, \dots, n$$

Zmienną losową  $X_i$  interpretujemy jako zmianę pozycji pionka w  $i$ -tym kroku – w skrócie będziemy ją nazywać  **$i$ -tym krokiem**. Wówczas

$$S_i = X_1 + X_2 + \dots + X_i, \quad i = 1, 2, \dots, n$$

oznacza **pozycję** pionka po  $n$  krokach. Ciąg  $(S_1, S_2, \dots)$  kolejnych pozycji nazywamy **trajektorią** spaceru losowego. Na gruncie teorii możemy rozważać nieskończone spacery losowe, tzn. przyjmować  $n = \infty$ . Takie nieskończone spacery losowe mają następującą własność.

**Twierdzenie (prawo iterowanego logarytmu).** Niech  $S_1, S_2, \dots$  będzie trajektorią nieskończonego prostego spaceru losowego. Wówczas

$$\limsup_{n \rightarrow \infty} \frac{S_n}{\sqrt{2n \log \log n}} = -\liminf_{n \rightarrow \infty} \frac{S_n}{\sqrt{2n \log \log n}} = 1 \quad \text{z prawdopodobieństwem 1.}$$

Tutaj  $\log$  oznacza logarytm naturalny. Sprawdźmy działanie prawa iterowanego logarytmu na skończonym spacerze losowym.

W poniższych zadaniach powinno się używać bibliotek:

```
[]: import numpy as np
import matplotlib.pyplot as plt
```

**Zadanie 1.** Wylosuj 30 razy po  $n = 200$  kroków spaceru losowego i zapisz je w macierzy `numpy.ndarray` z 200 wierszami i 30 kolumnami, tj. rozmiaru (200,30)

*Przydatne funkcje i parametry:* `np.choice()`

**Zadanie 2.** Wykorzystaj kroki spacerów losowych z utworzonej macierzy numpy do obliczenia trajektorii. Wynikiem powinna być macierz numpy, zawierająca w każdej z 30 kolumn trajektorię jednego spaceru losowego długości  $n = 200$ .

*Przydatne funkcje:* `np.cumsum()`

**Zadanie 3.** Narysuj wykresy dwóch funkcji  $f(x) = \sqrt{2x \log \log x}$  oraz  $g(x) = -f(x)$ . Skala na osi  $X$  powinna przebiegać od 0 do 200. Skalę na osi  $Y$  dobierz optymalnie do wartości obu funkcji. Wykresy powinny być narysowane czarną linią przerywaną grubości 2.

*Przydatne funkcje i argumenty:* `plt.plot()`, `np.sqrt()`, `np.log()`, `plt.xlim()`, `plt.ylim()`, `plt.legend()`, `np.e`

**Zadanie 3.5.** Zastanów się, dlaczego przy tworzeniu wykresów wyświetla się (może zależeć od Twojego wyboru wartości na osi  $X$ ) komunikat ostrzegawczy. Dla jakich  $x$  funkcje  $f(x)$  i  $g(x)$  są dobrze zdefiniowane?

**Zadanie 4.** Dorysuj do wykresu wykresy liniowe dla wszystkich 30 trajektorii spacerów losowych. Użyj funkcji `plt.cm.rainbow()` do zdefiniowania 30 kolorów – jednego dla każdej trajektorii. Ustaw poziom krycia `alpha` tak, aby wykresy funkcji narysowane w poprzednim zadaniu pozostały wyraźne. Trajektorie powinny być narysowane liniami ciągłymi grubości 1.

*Przydatne funkcje i argumenty:* `np.linspace()`, `plt.plot()`, `plt.legend()`, `plt.show()`, `plt.cm.rainbow()`

*# Kolory dla trajektorii definiujemy następująco:*  
`colors = plt.cm.rainbow(np.linspace(0, 1, num_walks)) # tutaj: num_walks=30`

## Rozkład wykładniczy i gamma

Zmienna losowa  $X$  o rozkładzie wykładniczym z parametrem **intensywności**  $\lambda > 0$  ma gęstość i dystrybuantę:

$$f(x) = \lambda e^{-\lambda x}, \quad F(x) = 1 - e^{-\lambda x}, \quad x \geq 0.$$

Zmienna losowa  $Y$  ma rozkład Gamma z parametrami **kształtu** (shape)  $\alpha$  oraz **skali** (scale)  $\beta > 0$  jeśli ma gęstość

$$f(x) = \frac{1}{\beta^\alpha \Gamma(\alpha)} x^{\alpha-1} e^{-\frac{x}{\beta}}, \quad x \geq 0.$$

*Uwaga:* Czasami podawany jest rozkład z parametrami kształtu  $\alpha > 0$  oraz parametrem **intensywności**, który jest odwrotnością parametru skali, tj.  $\lambda = 1/\beta$ , wówczas gęstość wyraża się wzorem

$$f(x) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x}, \quad x \geq 0.$$

Przez rozkład  $\text{Gamma}(\alpha, \beta)$  rozumiemy rozkład z parametrem **kształtu**  $\alpha$  oraz **skali**  $\beta$

Założmy, że zmienne losowe  $X$  i  $Y$  są niezależne i mają rozkład wykładniczy  $\text{Exp}(\lambda)$ . Wówczas suma  $Z = X + Y$  ma rozkład  $\text{Gamma}(2, \lambda)$ .

**Zadanie 5.** Wylosuj dwie stuelementowe próby  $X, Y$  z rozkładu  $\text{Exp}(2)$ .

*Przydatne funkcje:* `numpy.random.exponential()`

*Uwaga:* funkcja `numpy.random.exponential()` przyjmuje parametr skali. Zatem wylosowanie  $\text{Exp}(\lambda)$  wygląda tak:

**Zadanie 6.** Użyj wektorów  $X$  i  $Y$  do stworzenia wektora  $Z=X+Y$ .

**Zadanie 7.** Narysuj histogram gęstościowy zmiennej  $Z$ .

*Przydatne funkcje i argumenty:* `np.hist()`, `plt.hist()`

**Zadanie 8.** Dorysuj do histogramu wykres gęstości rozkładu  $\text{Gamma}(2,2)$ .

*Przydatne funkcje i argumenty:* `scipy.stats.gamma.pdf`

```
[ ]: # Gamma: symulowanie zmiennych losowych, funkcja gęstości, dystrybuanta
    # przy użyciu biblioteki scipy.stats:

from scipy.stats import gamma

shape=3
scale=1/5

gamma_samples = gamma.rvs(a=3, scale=scale, size=100) # probka rozm. 100
x=np.linspace(0,5,200)

gamma_pdf = gamma.pdf(x, a=shape, scale=scale)
gamma_cdf = gamma.cdf(x, a=shape, scale=scale)

plt.plot(x,gamma_pdf, label='pdf')
plt.plot(x,gamma_cdf, label='cdf')
plt.legend()
plt.show()
```